

CURSO PRÁTICO DE DEEP LEARNING COM PYTHON E KERAS

Como melhorar seu modelo =O

Conjuntos de treinamento/teste



treino

validação

teste

- ▷ Divisões usadas: 70/30, 60/20/20, 50/25/25
- ▷ Big data (1.000.000)
 - 98/1/1/

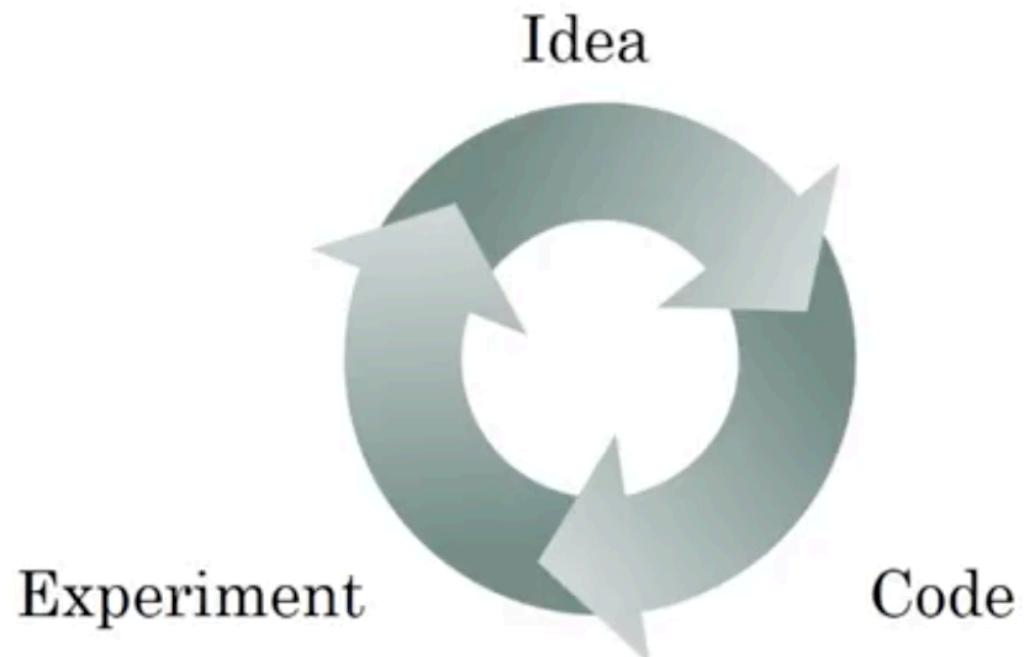
Distribuição incorreta

Conjunto de treino:
figuras de gatos de
webpages

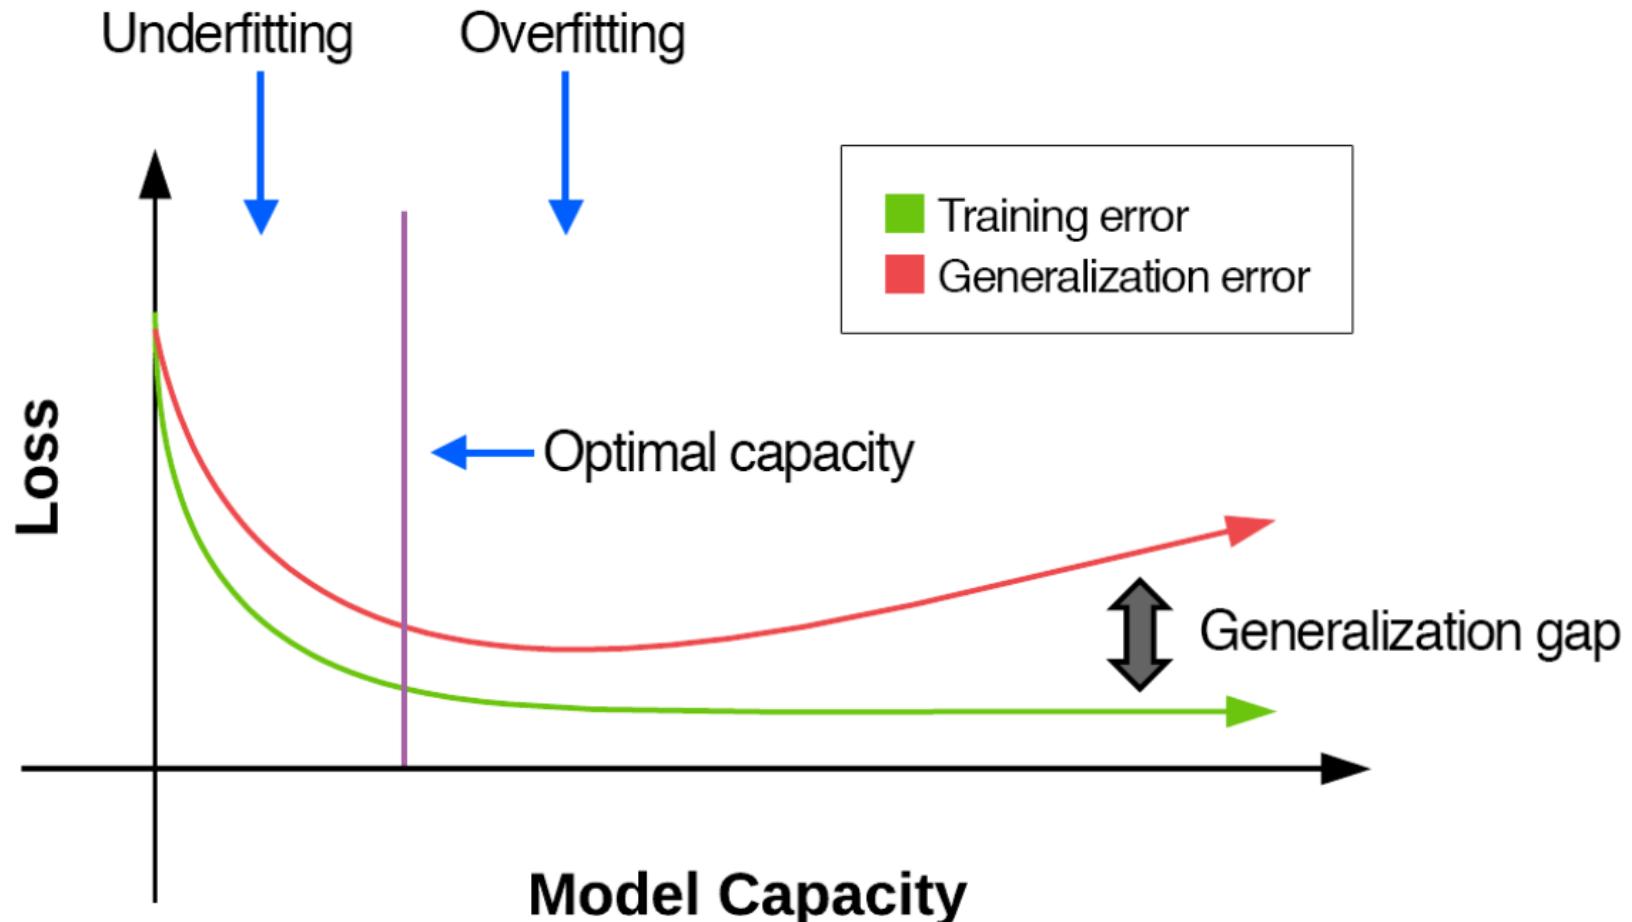
Conjunto de Valid./teste:
Figuras de gatos usando
seu aplicativo

ML é um processo iterativo

- ▷ # camadas
- ▷ # unidades escondidas
- ▷ Taxas de aprendizado
- ▷ Funções de ativação



Overfitting e Underfitting

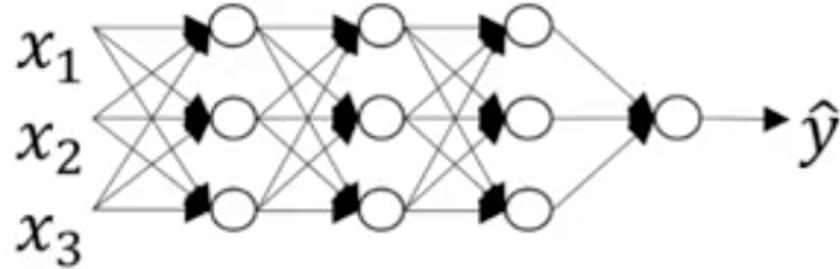


Regularização

$$L = \frac{1}{N} \sum_{i=1}^N [-\log(e^{s_{y_i}} / \sum_j e^{s_j})] + \lambda \sum_i \sum_j W_{i,j}^2$$

- ▷ Adiciona uma penalidade para valores altos de pesos
 - Parâmetro de ajuste λ

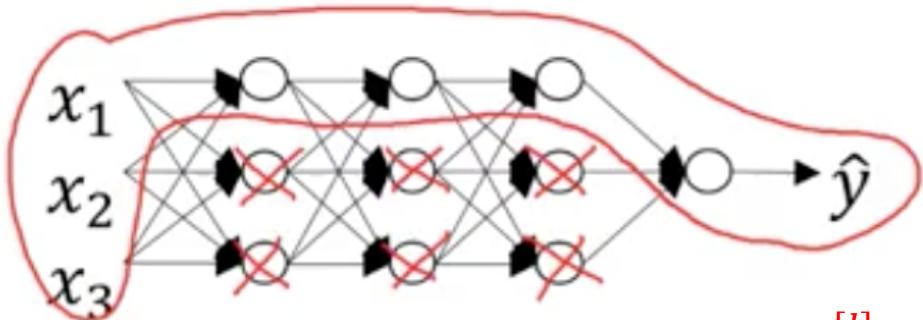
Por que a regularização previne overfitting?



$$L = \frac{1}{N} \sum_{i=1}^N [-\log(e^{s_{y_i}} / \sum_j e^{s_j})] + \lambda \sum_i \sum_j W_{i,j}^2$$



Por que a regularização previne overfitting?



$$L = \frac{1}{N} \sum_{i=1}^N [-\log(e^{s_{y_i}} / \sum_j e^{s_j})] + \lambda \sum_i \sum_j W_{i,j}^2$$

$$w^{[l]} \approx 0$$

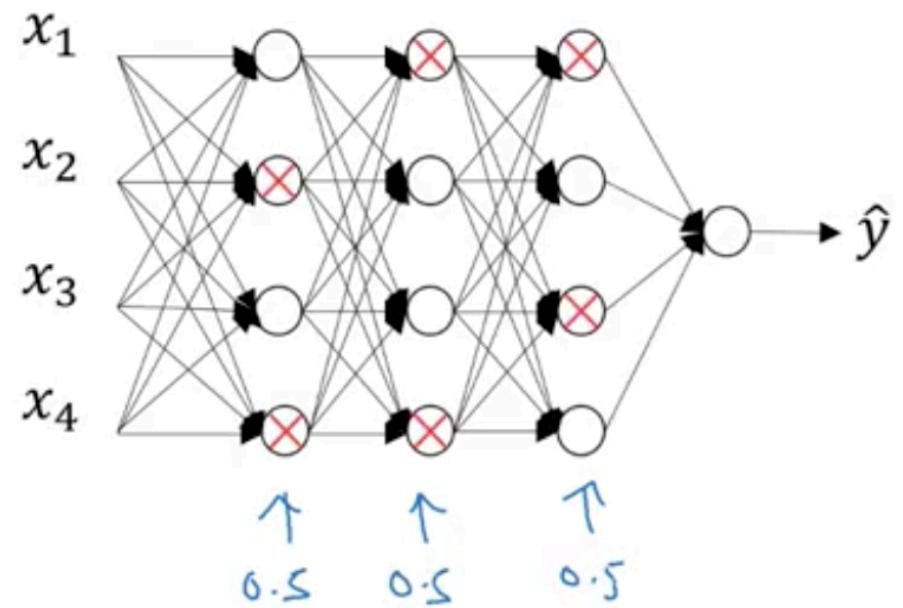
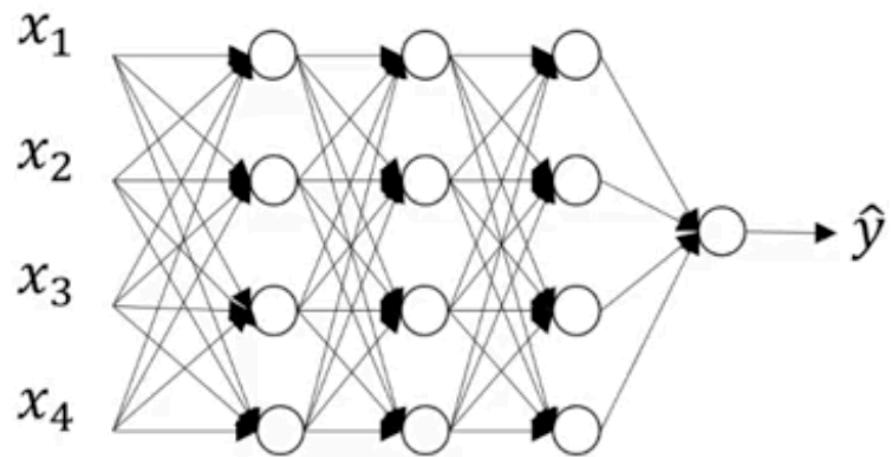
Regularização no Keras

```
from keras import regularizers
model.add(Dense(64, input_dim=64,
                kernel_regularizer=regularizers.l2(0.01),
                activity_regularizer=regularizers.l1(0.01)))
```

Exercício

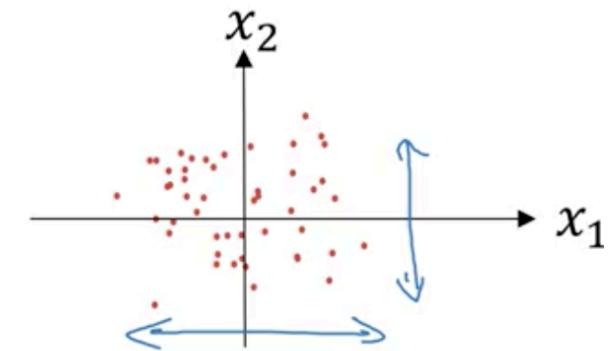
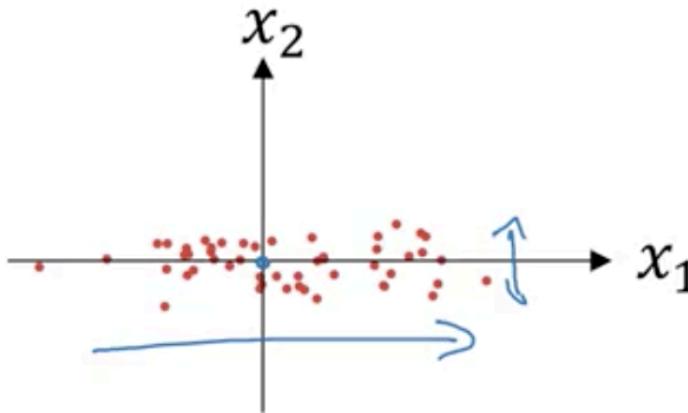
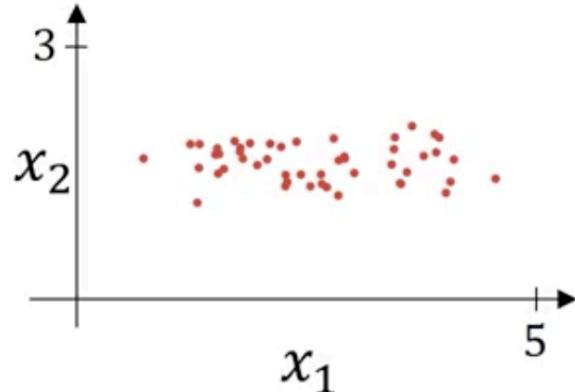
- ▷ Adicionar regularização
 - LeNet_optimizer.ipynb

Dropout



Normalizando Conjunto de Treino

▷ Média zero



Subtract mean:

$$\hat{\mu} = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

$$\underline{x := x - \mu}$$

Normalize variance

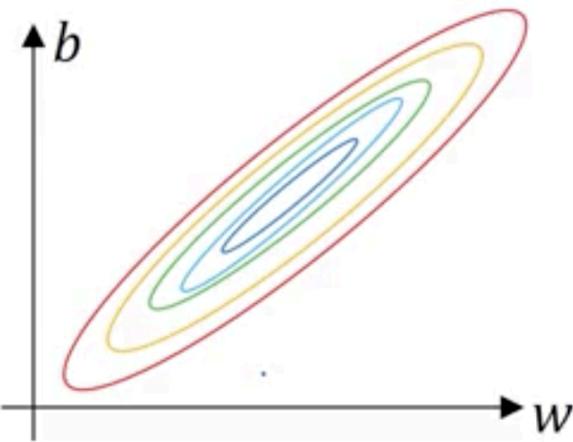
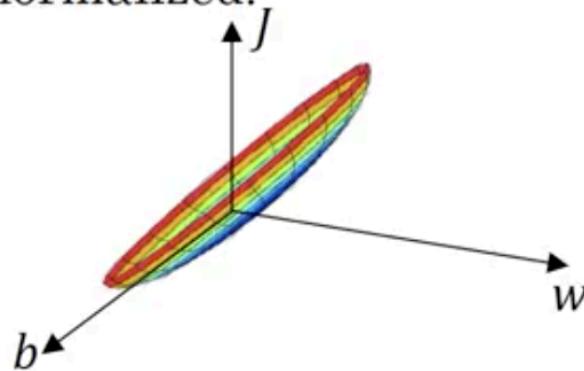
$$\frac{1}{m} \sum_{i=1}^m x^{(i)} \times x^2$$

← element-wise

$$x / = \sigma^2$$

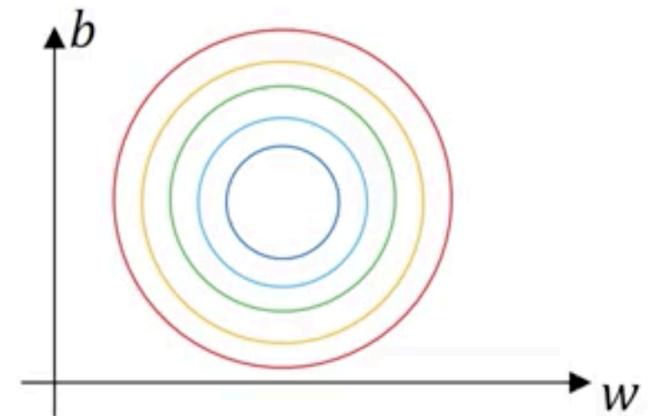
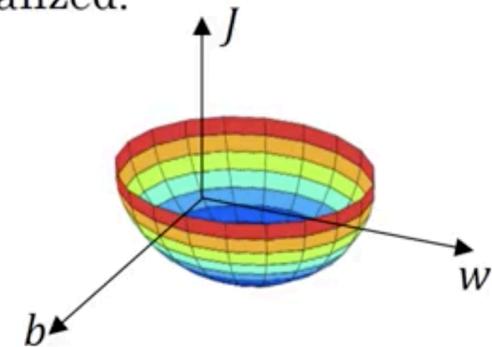
Por que normalizar entradas?

Unnormalized:



$$J(w, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)})$$

Normalized:



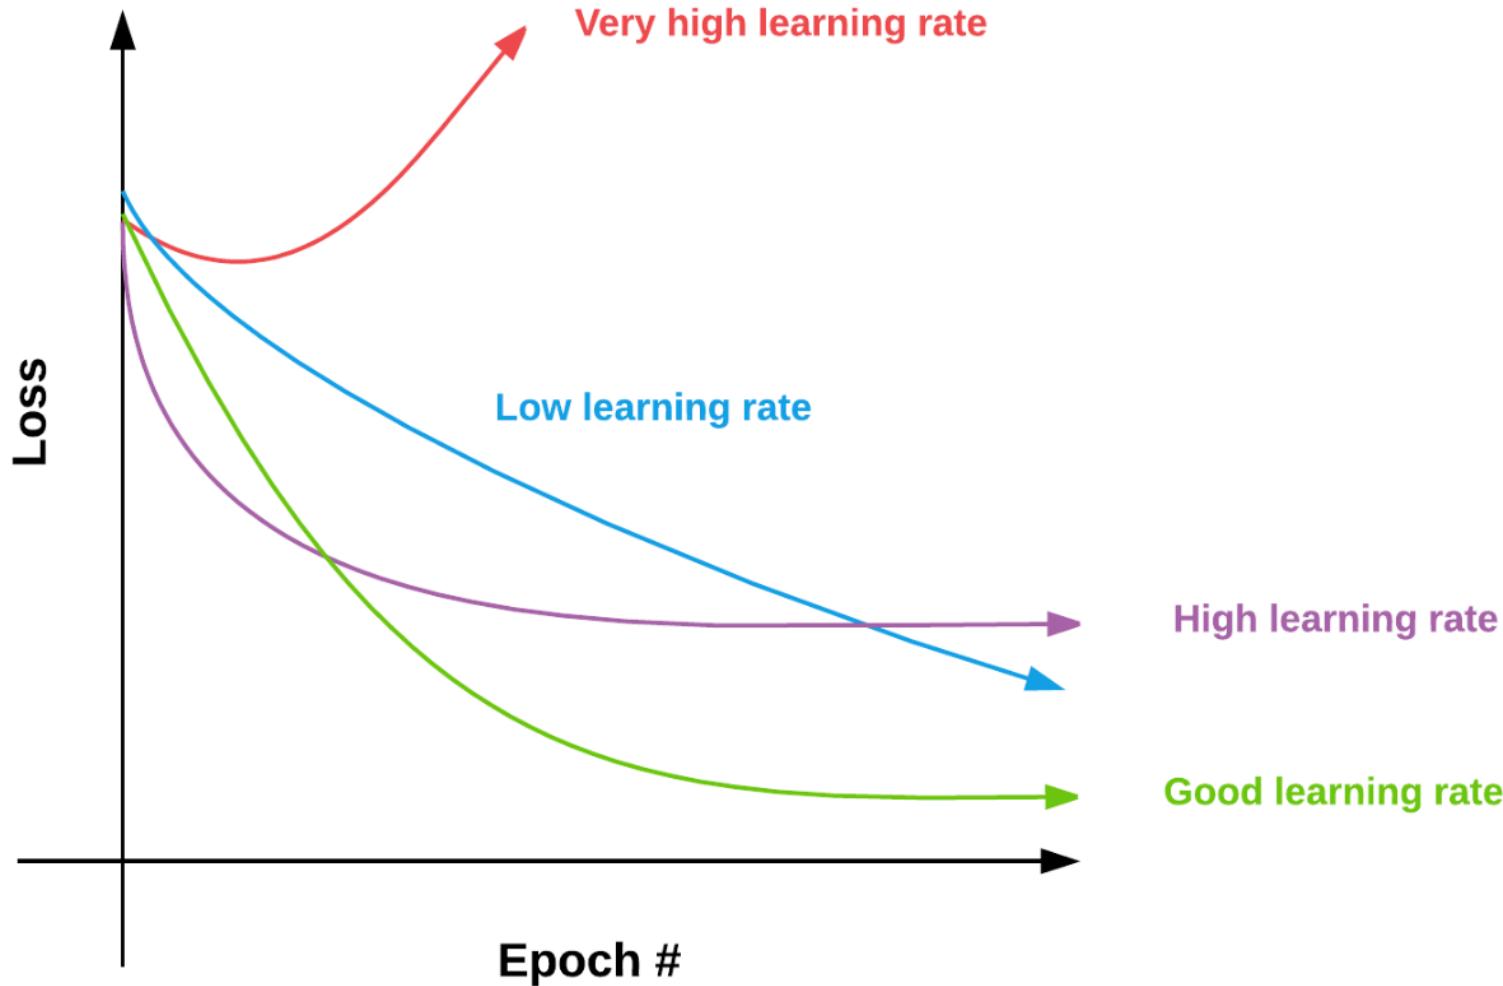
Métodos de Otimização

- ▷ SGD
- ▷ Adagrad
- ▷ Adadelta
- ▷ RMSProp
- ▷ Adam
- ▷ NAdam

Taxa de Aprendizado



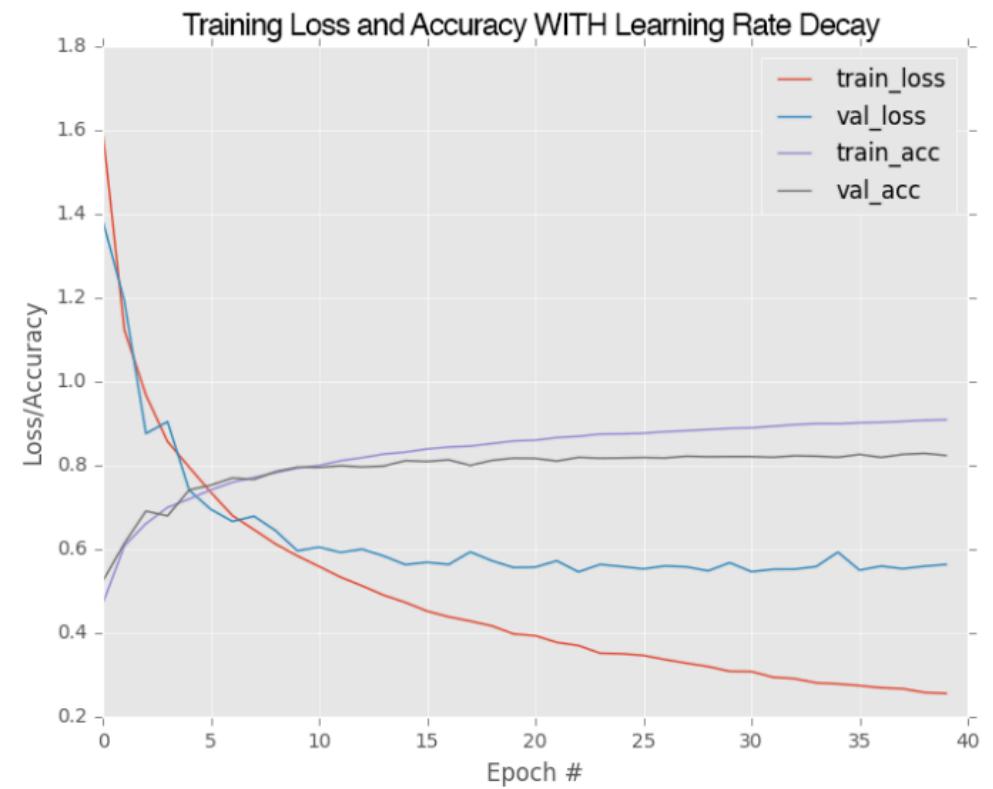
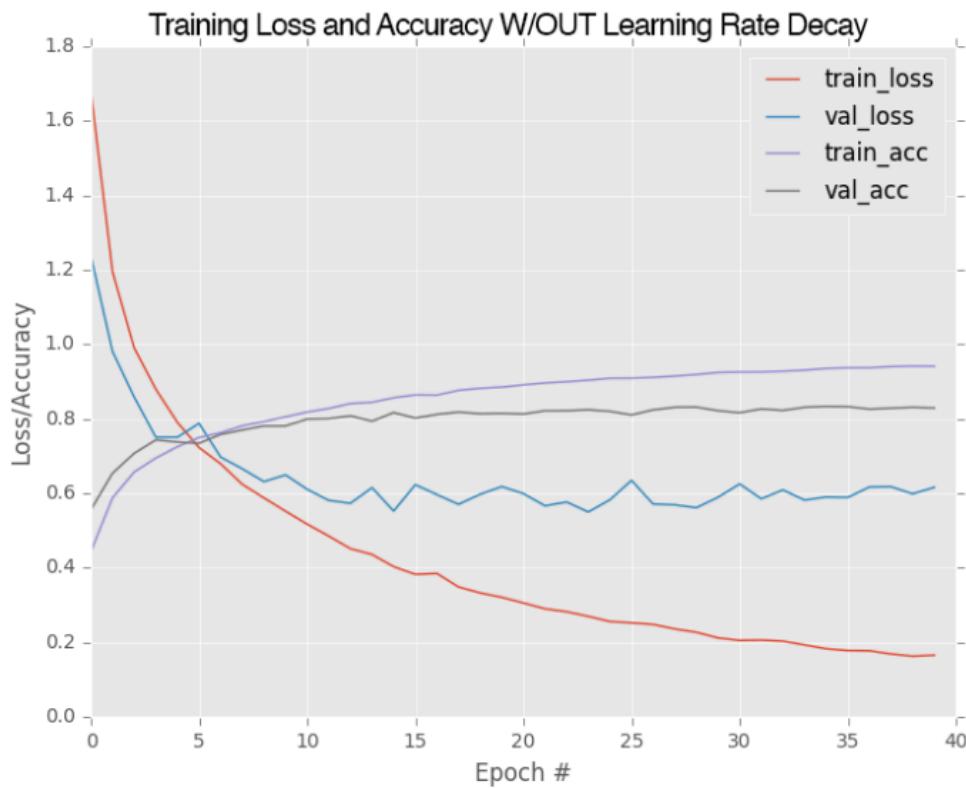
Efeitos da taxa de aprendizado



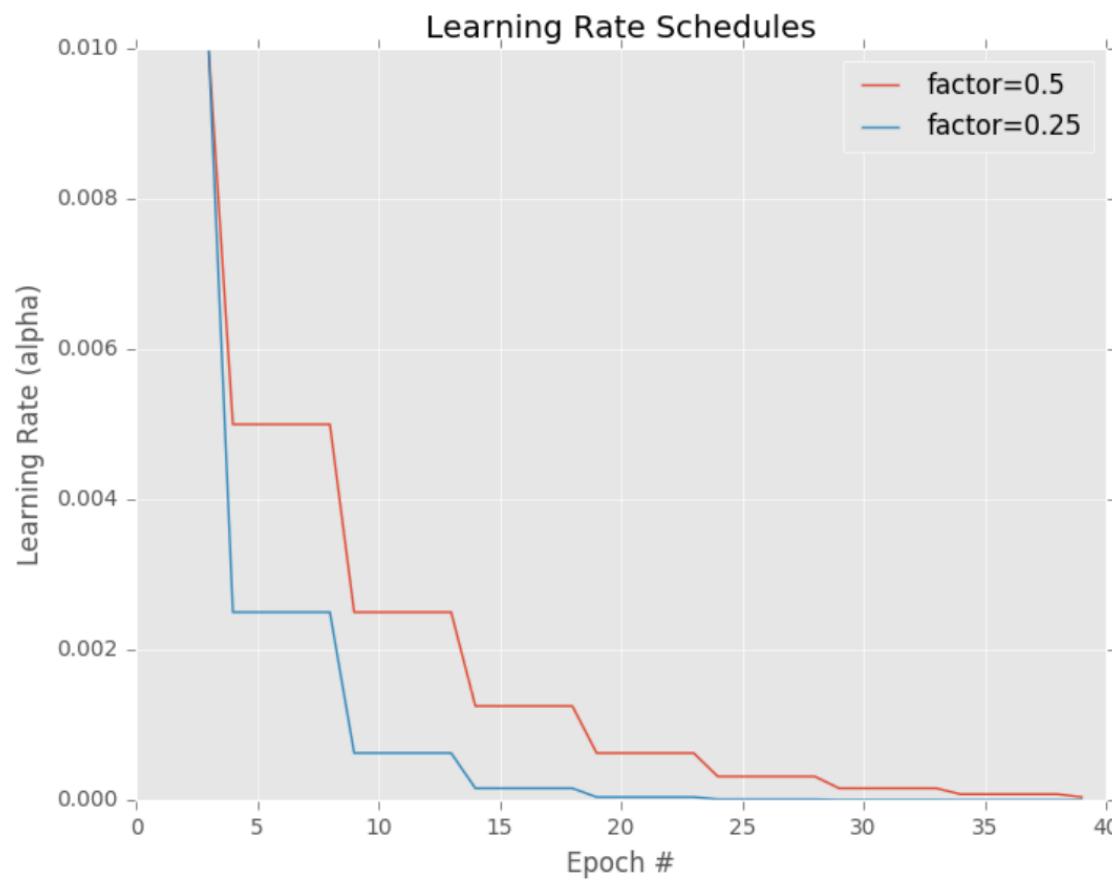
Learning Rate Decay

```
# initialize the optimizer and model
print("[INFO] compiling model...")
opt = SGD(lr=0.01, decay=0.01 / 40, momentum=0.9, nesterov=True)
model = MiniVGGNet.build(width=32, height=32, depth=3, classes=10)
model.compile(loss="categorical_crossentropy", optimizer=opt,
metrics=["accuracy"])
```

Epoch	Learning Rate (α)
0	0.01000
1	0.00836
2	0.00719
...	...
37	0.00121
38	0.00119
39	0.00116



Step-based Decay



Exercício

▷ Adicionar no LeNet

- Dropout
- Batch normalization
- Usar otimizador diferente de SGD
- Usar learning rate com decaimento

Data Augmentation

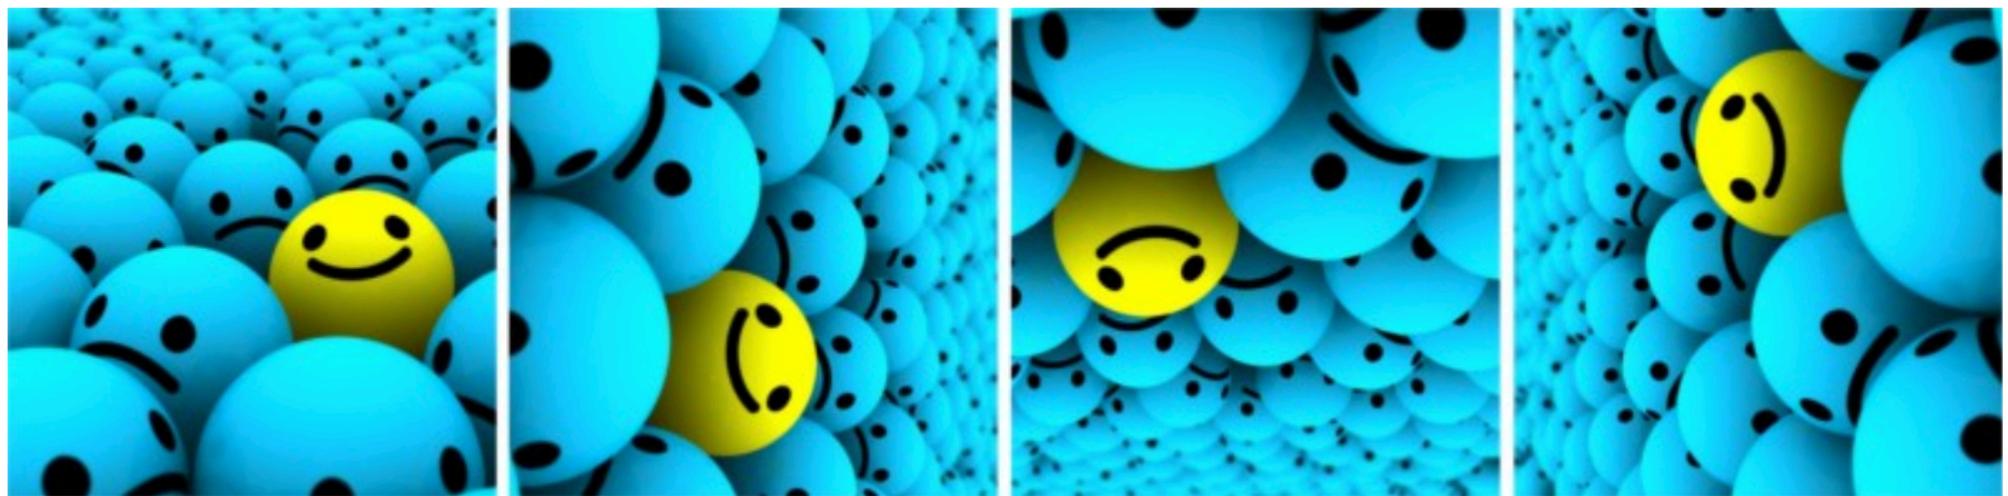
▷ Aplicar transformações na imagem:

- Translação
- Rotação
- Escala
- Flips
- ...

Flip



Rotação



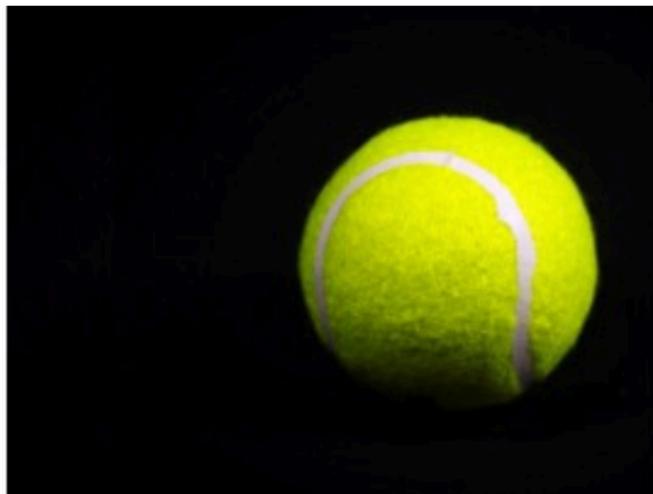
Escala



Crop

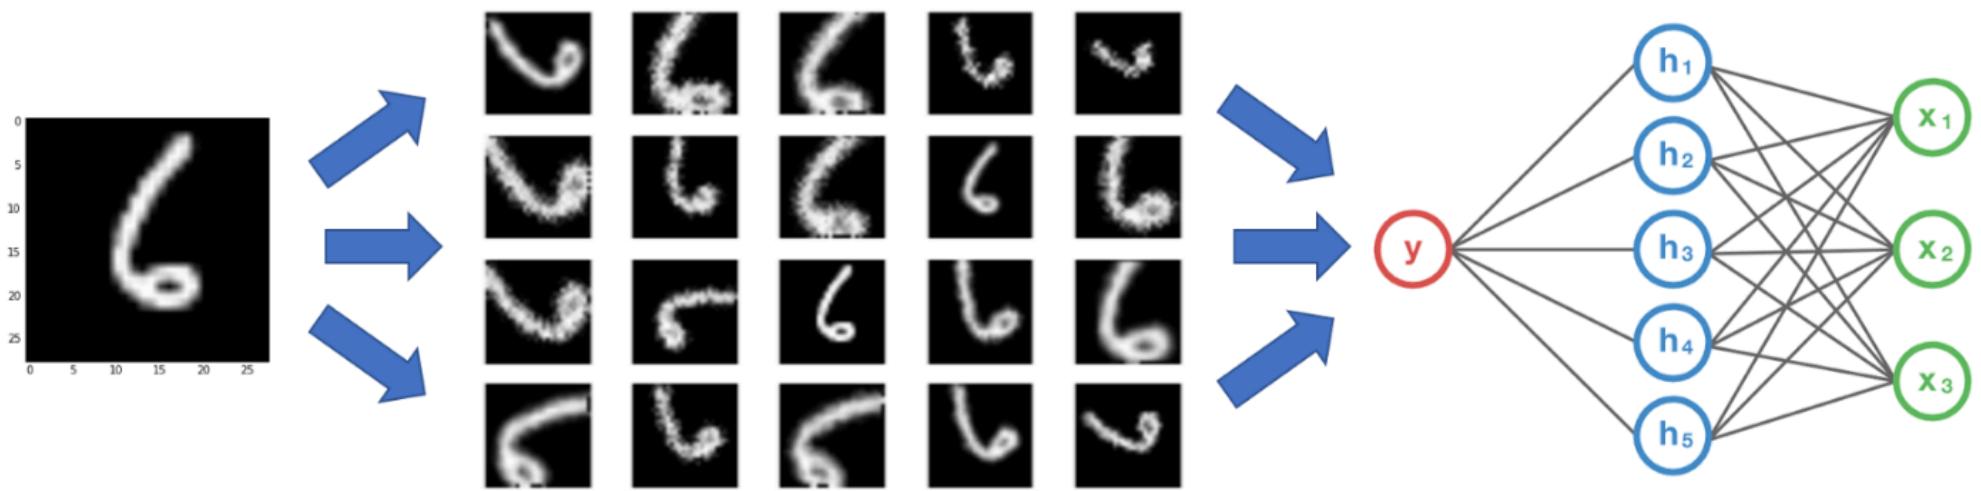


Translação



Ruído Gaussiano





Data Augmentation no Keras

```
1 from keras.preprocessing.image import ImageDataGenerator  
2  
3 generator = ImageDataGenerator(rescale = 1./255,  
4                                 width_shift_range=0.1,  
5                                 height_shift_range=0.1,  
6                                 rotation_range = 20,  
7                                 shear_range = 0.3,  
8                                 zoom_range = 0.3,  
9                                 horizontal_flip = True)
```

```
1 train = generator.flow_from_directory('../data/generator',  
2                                         target_size = (128, 128),  
3                                         batch_size = 32,  
4                                         class_mode = 'binary')
```

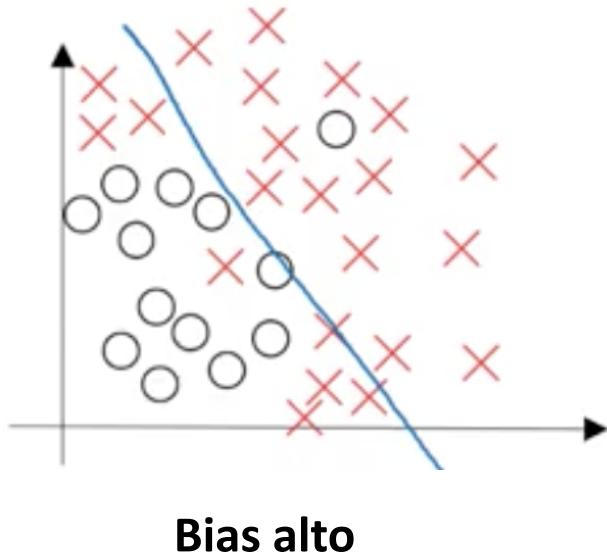
```
H = model.fit_generator(  
    aug.flow(trainX, trainY, batch_size=BS),  
    validation_data=(testX, testY),  
    steps_per_epoch=len(trainX) // BS,  
    epochs=EPOCHS, verbose=1)
```

Data augmentation

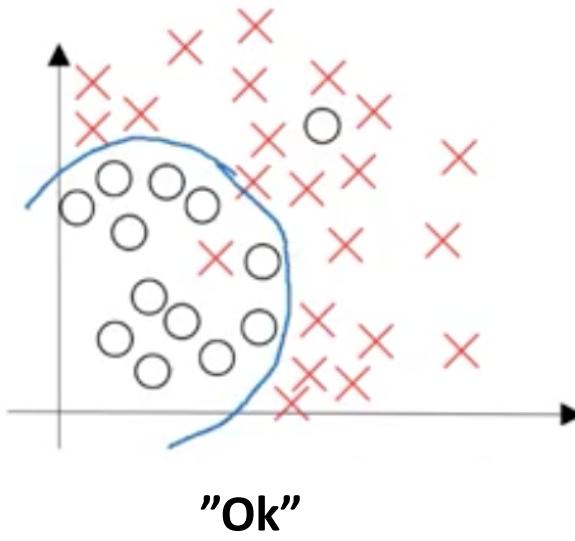
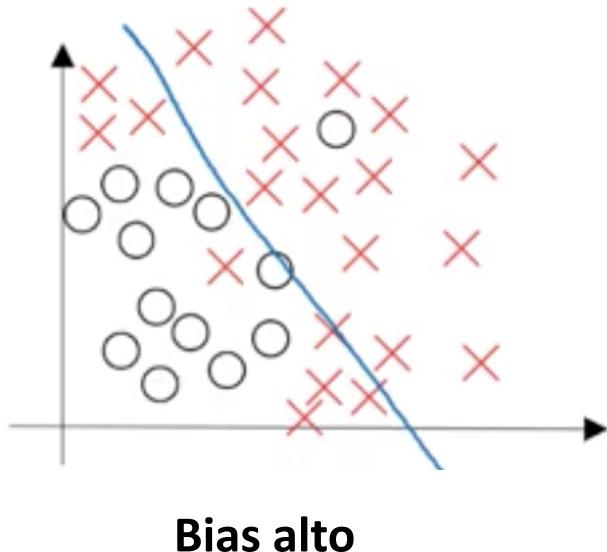
▷ Código

- Augmentation.ipynb

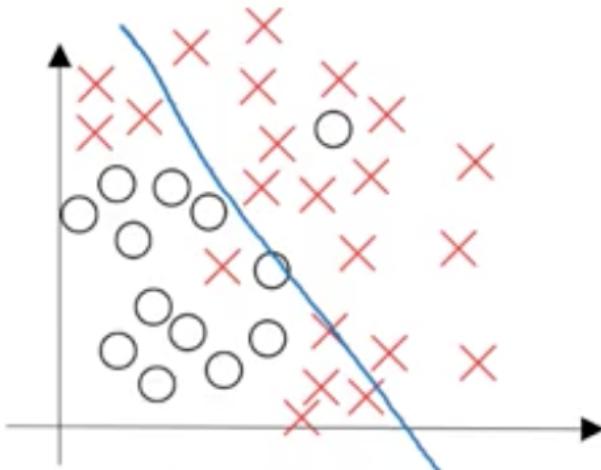
Bias x Variância



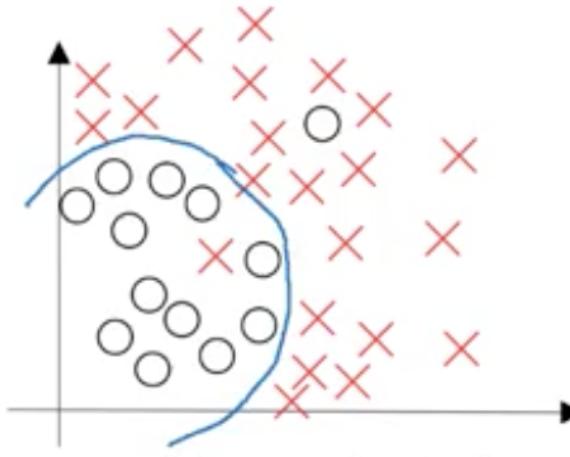
Bias x Variância



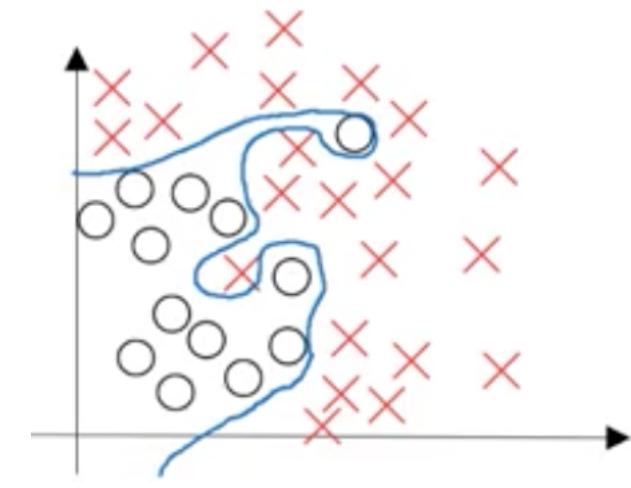
Bias x Variância



Bias alto

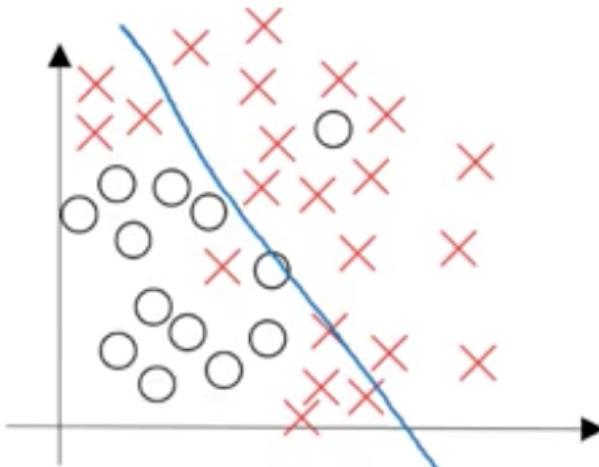


"Ok"



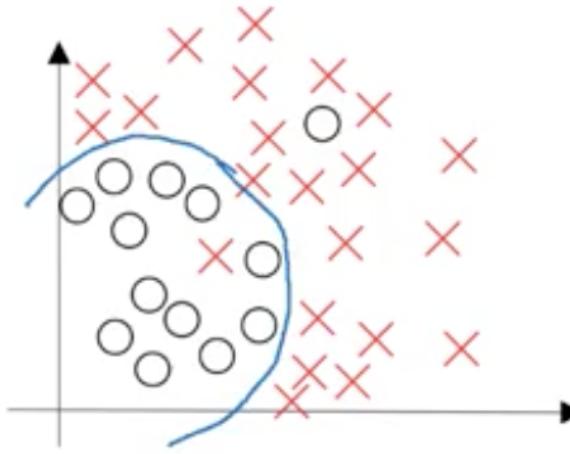
Variância alta

Bias x Variância

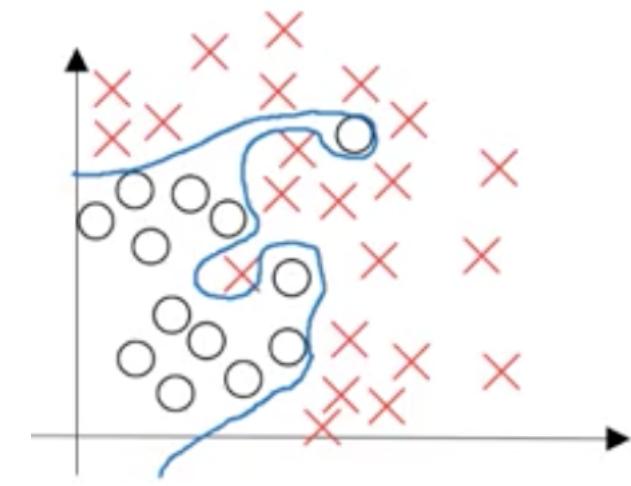


Bias alto

underfitting



"Ok"



Variância alta

overfitting

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

Erro do conjunto de teste:

11%

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

Erro do conjunto de teste:

11%

Variância
alta

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

Erro do conjunto de teste:

15%

16%

Variância
alta

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

15%

16%

Variância
alta

Bias alto

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

Erro do conjunto de teste:

15%

16%

15%

30%

Variância
alta

Bias alto

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

Variância
alta

15%

16%

Bias alto

Erro do conjunto de teste:

15%

30%

- Variância
alta
- Bias alto

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

Variância alta

15%

16%

Bias alto

15%

30%

- Variância alta
- Bias alto

0.5%

1%

Erro do conjunto de teste:

Humano: $\approx 0\%$

Bias e Variância

Classificação de gato

$y=1$



$y=0$



Erro do conjunto de treino:

1%

11%

Variância
alta

15%

16%

Bias alto

15%

30%

- Variância
alta
- Bias alto

0.5%

1%

- Variância
baixa
- Bias baixo

Erro do conjunto de teste:

Humano: $\approx 0\%$

Receita básica para ajustar modelo

Bias alto?
(conjunto de treino)

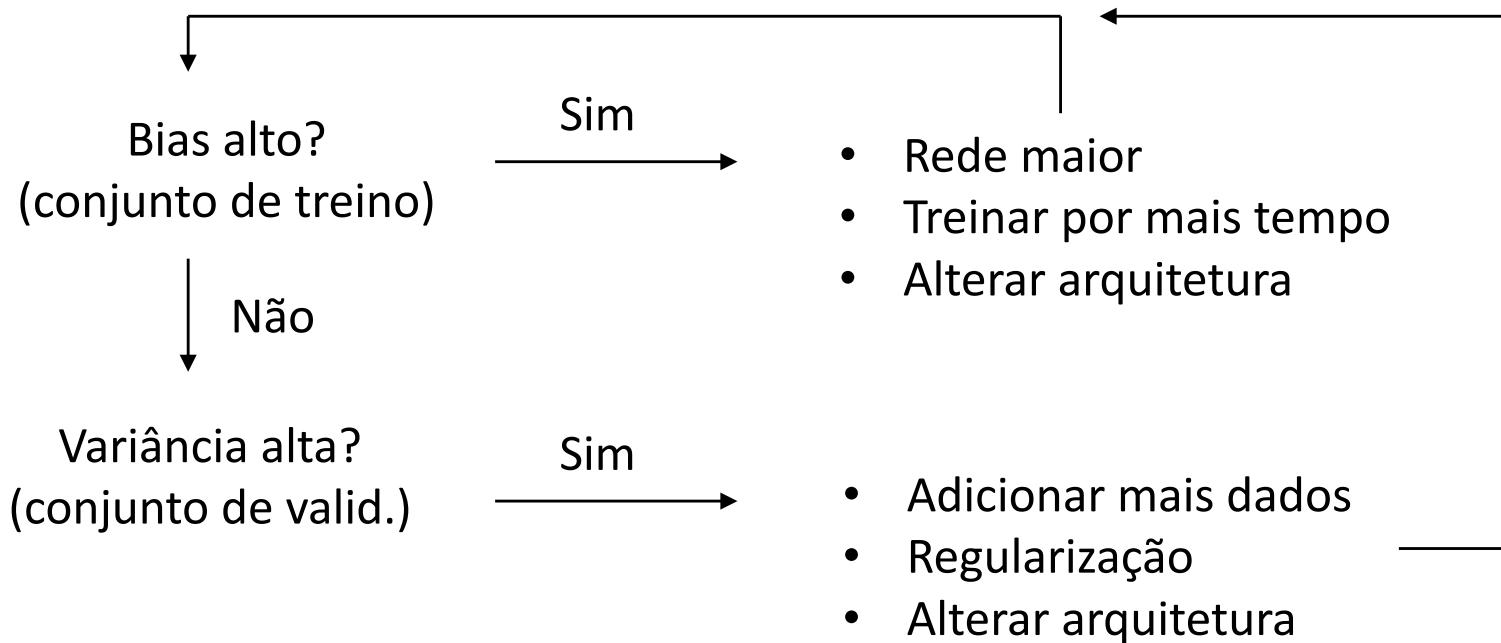
Receita básica para ajustar modelo



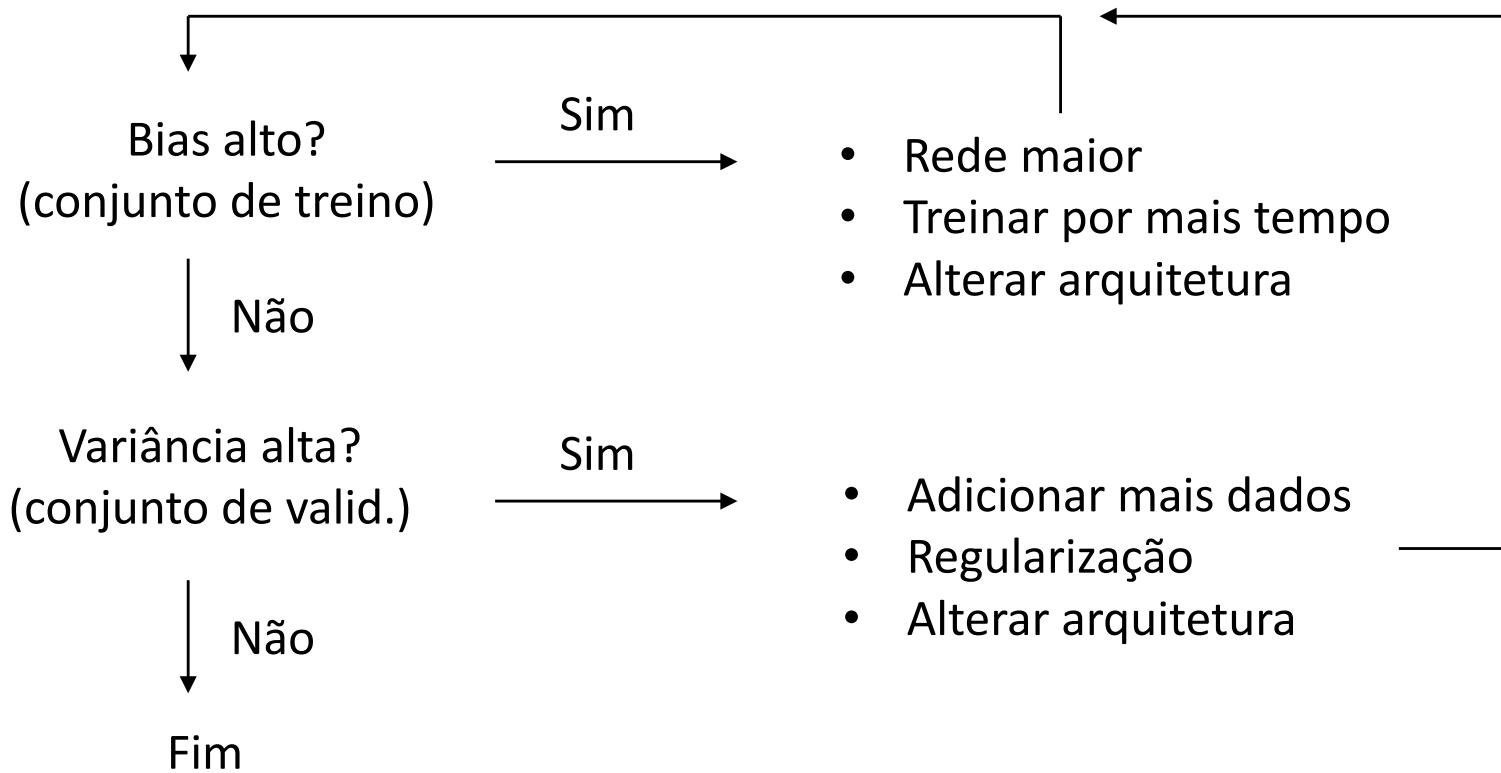
Receita básica para ajustar modelo



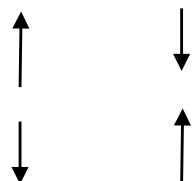
Receita básica para ajustar modelo



Receita básica para ajustar modelo



“Bias variance tradeoff”



Cadeia de validações em ML

Conjunto de treino se ajusta bem à função de custo
(≈perfomance humana)



Rede maior
Adam
...

↓
Conjunto de validação se ajusta bem à função de custo



Regularização
Maior conjunto de treino
...

↓
Conjunto de teste se ajusta bem à função de custo



Maior conjunto de validação

↓
Desempenha bem no mundo real



Mudar conjunto de validação ou
função de custo

Resumo

▷ Ideias

- Coletar mais dados
- Adquirir conjunto de treino mais diverso
- Treinar o algoritmo por mais tempo
- Tentar Adam ao invés de Gradiente descendente
- Tentar rede maior
- Tentar rede menor
- Adicionar dropout
- Adicionar Regularização L2
- Ajustar arquitetura da rede
 - Função de ativação
 - # camadas escondidas
 - Taxa de aprendizado
 - ...

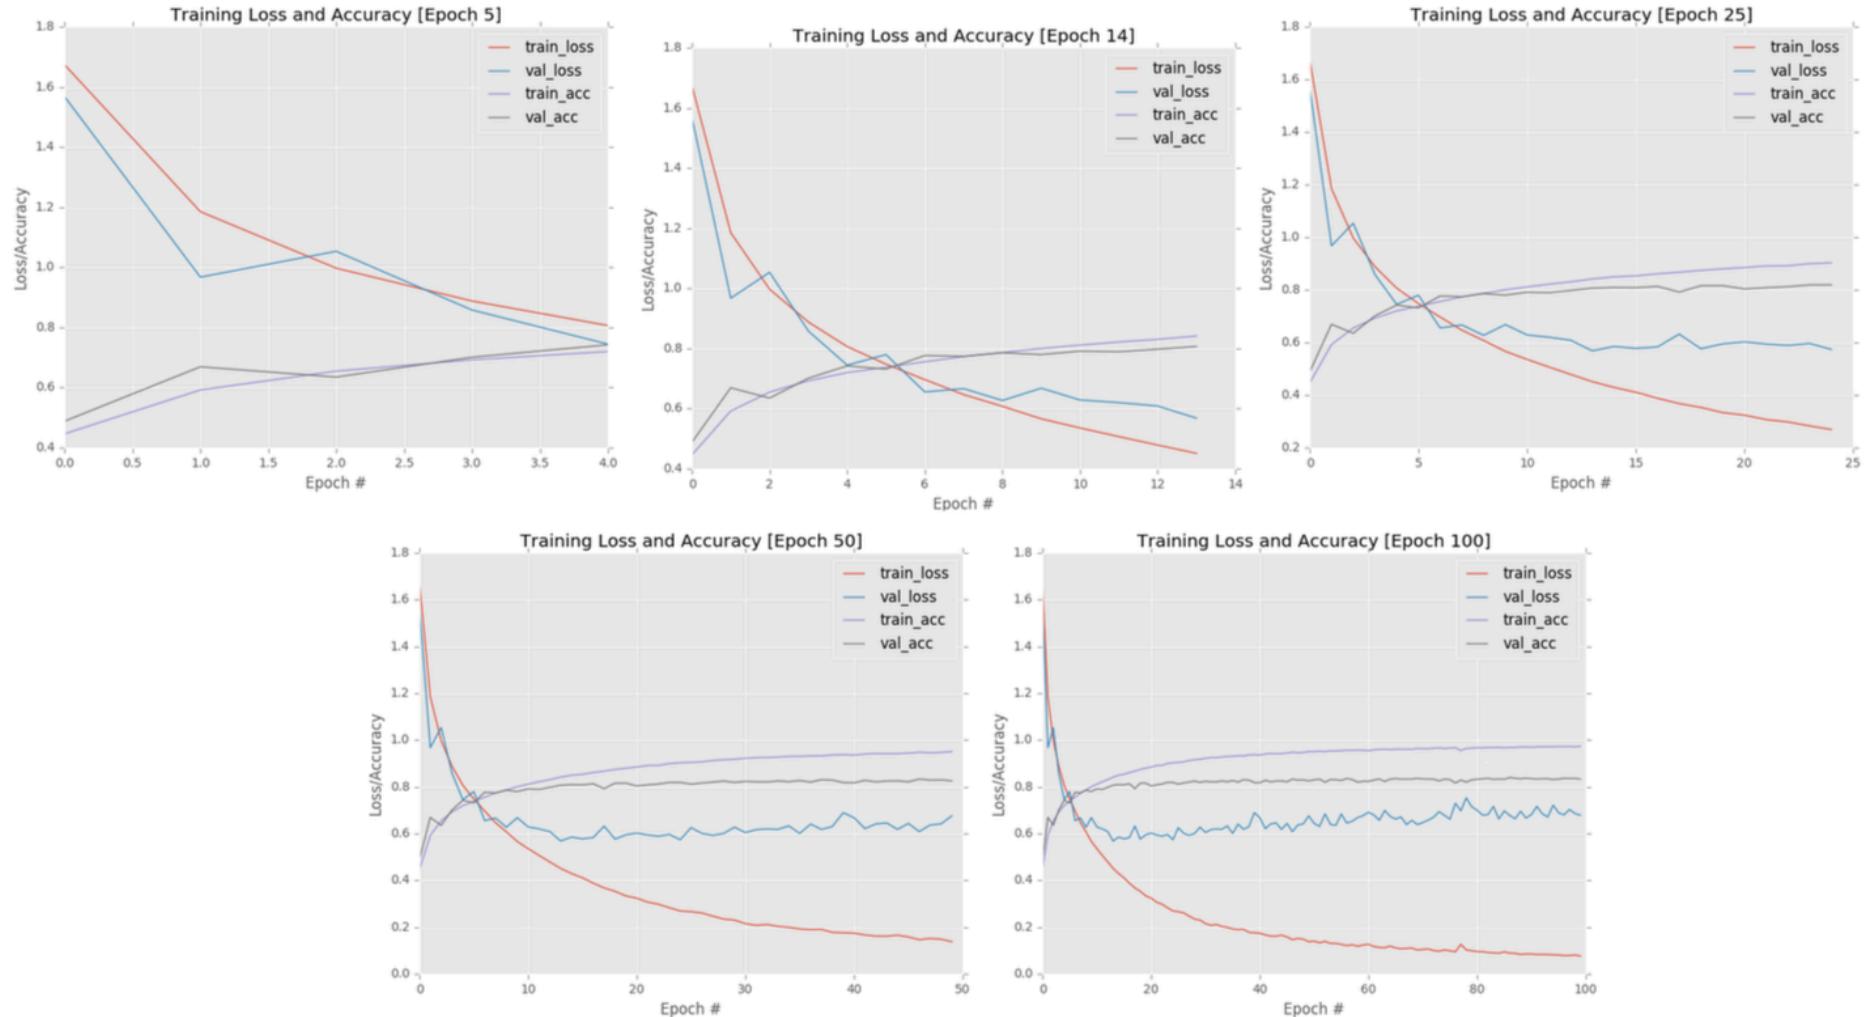
Estudo de Caso 1

▷ Esse problema é adaptado de uma aplicação real



▷ Estudo de Caso1.ipynb

Monitorando o processo de treino



Preste atenção na curva de treinamento

- ▷ Você está aplicando alguma regularização?
- ▷ Sua taxa de aprendizado está alta?
- ▷ Sua rede é muito profunda?

MiniGoogleNet - Experimentos

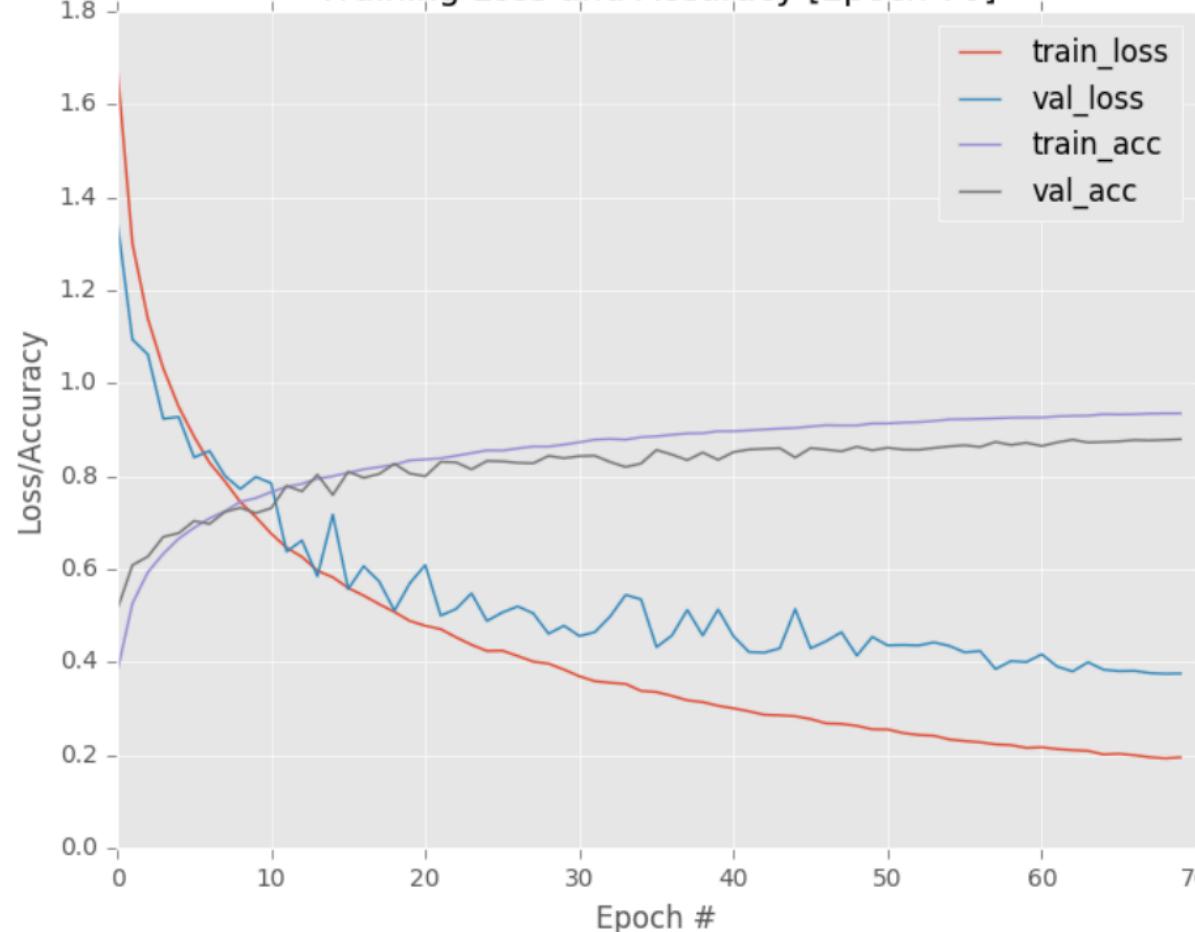
▷ Experimento 1

- Lr = 0.001

Acurácia = 87,5%

Experiment #1

Training Loss and Accuracy [Epoch 70]

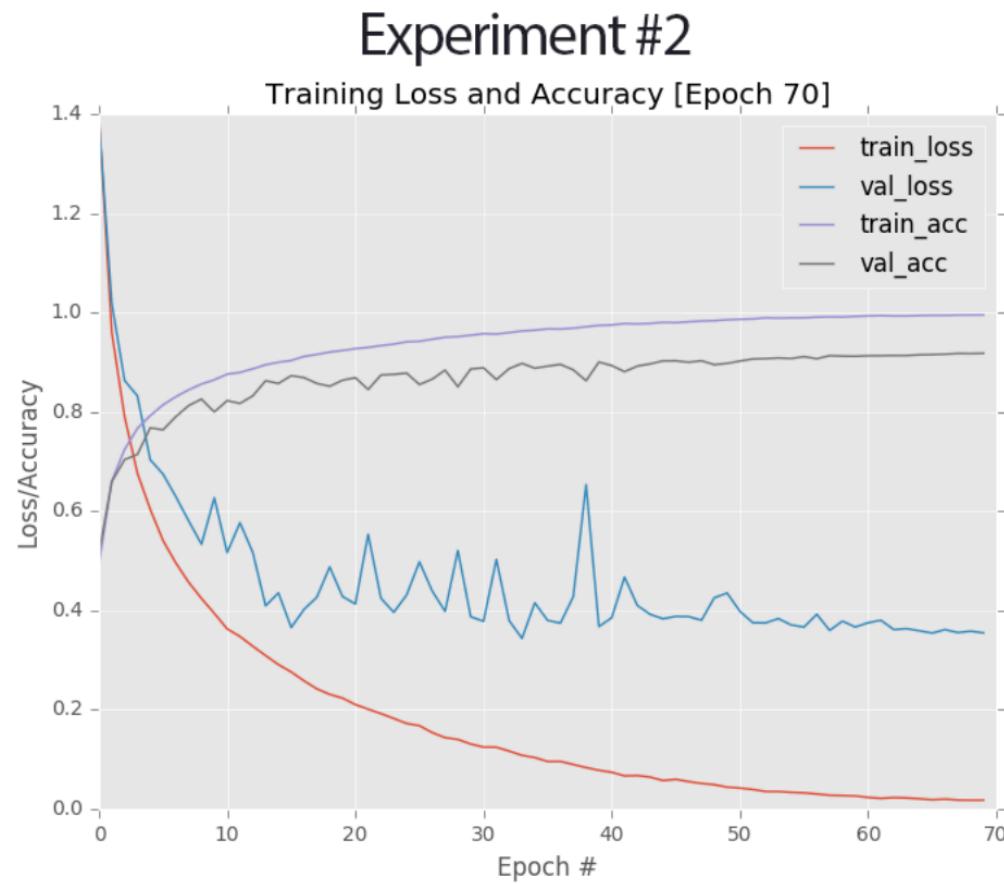


MiniGoogleNet - Experimentos

▷ Experimento 2

- Lr = 0.001-> 0.01

Acurácia = **91,79%**



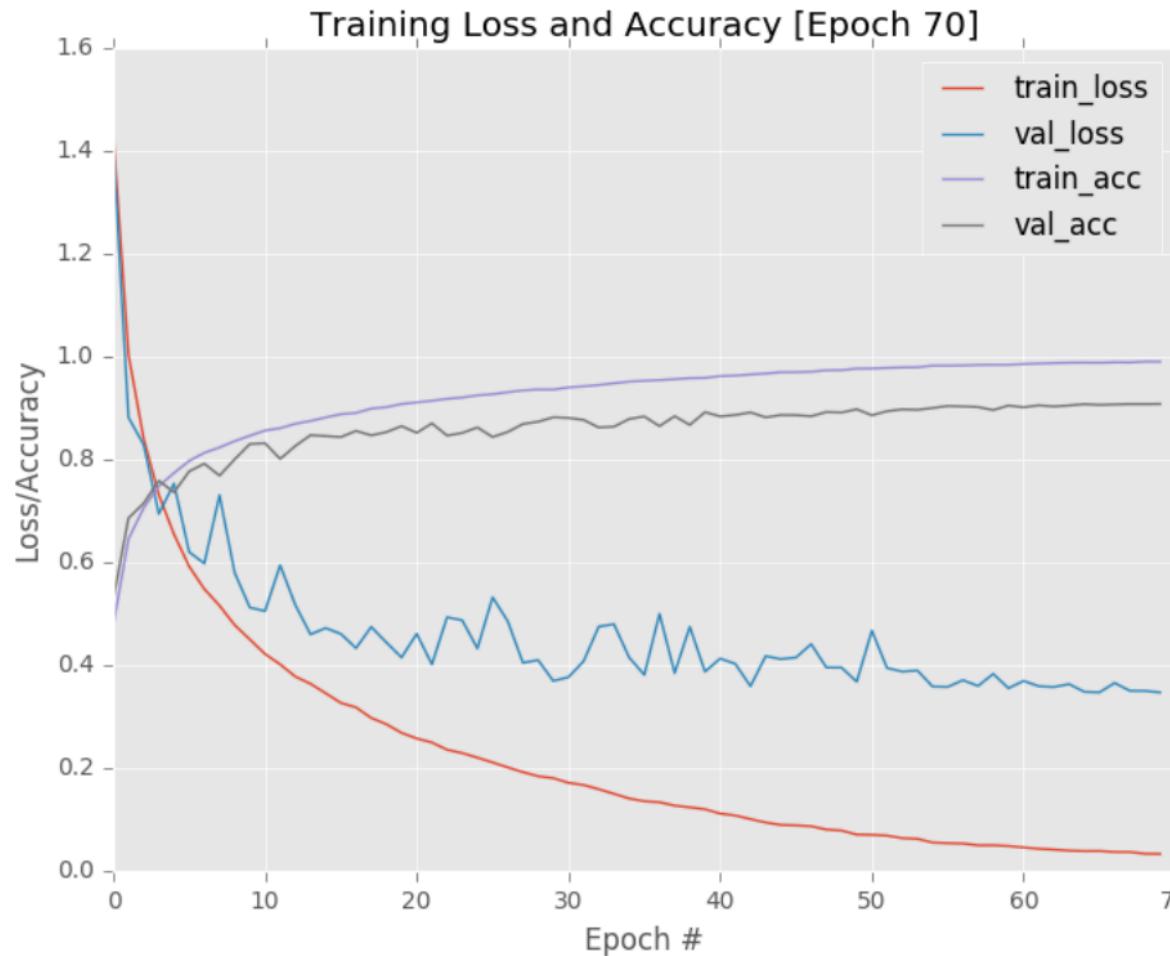
MiniGoogleNet - Experimentos

▷ Experimento 3

- Lr = 0.001-> 0.01 ->0,005

Acurácia = **90,81%**

Experiment #3



Método Ctrl+c – Resnet + cifar10



Ensembles



